

ResNetによる表情画像分類

集積回路情報研究室(ES1)

茨木 悠太

2026/6/24

目次

1. はじめに
2. 要素技術
3. 実装モデル
4. 実験
5. まとめ



研究の背景


- 画像処理技術が様々な場面で用いられている
- AIは感情を持たないが、画像中の特徴から表情を分類することができる点に興味を持った



自動運転支援システム




カメラによる異常検出



表情認識

研究の目的

- 画像認識技術の基礎知識を得る




- CNNの理解
- 転移学習の理解
- ResNet18を用いて表情画像認識を実践
- 分類結果と誤分類傾向を分析する

CNN(畳み込みニューラルネットワーク)


- CNNは人間の脳の視覚野を模した機械学習のモデル
- 画像認識の分野などで用いられる

畳み込み層とプーリング層が多段に接続




ResNet

- ILSVR-2015において優勝のCNNモデル
- 非常に深い層での学習が可能
- Shortcut Connectionを利用したResidual BlockやBatch Normalizationが特徴のCNNモデル



ResNet18


- 本実験では18層のモデルを使用(優勝モデルは152層)
- 「ImageNet」と呼ばれる大規模画像データセットで学習されている
- ResNet18は比較的軽量であり，計算量と精度のバランスがよい



layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	$7 \times 7, 64, \text{stride } 2$				
conv2_x	56×56	$3 \times 3 \text{ max pool, stride } 2$				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9


転移学習

- 大規模データセットで学習済みのモデルを利用
- 学習済みモデルを初期値として用いる
- 目的のタスクに合わせて出力層を変更



実装モデル

- ResNet18の学習済みモデルを転移学習
- 入力画像はグレースケール画像
→RGBの3チャンネルに複製して3チャンネル化
- 全結合層を1000クラス→3クラスに変更



実験内容

■ FER-2013系データセットを用いた表情3クラス分類

- 使用した元ラベル : happy, angry, sad, neutral
- クラス再構成 :
 - happy → positive
 - angry + sad → negative (angryとsadを同数ずつ使用)
 - neutral → neutral
- disgust, fear, surprise は今回は使用しない

positive

happy



neutral



negative

angry



sad



実験

■ 実験条件

- ・データセット: FER-2013系表情画像データセット
- ・画像: 48×48 ピクセルのグレースケール顔画像
- ・学習条件: batch size: 16, epoch: 100, learning rate: 1.0×10^{-4}

データ枚数表

■ 評価指標

- ・正解率[%]

分割	positive	negative	neutral	合計
Train	4000	4000	4000	12000
Valid	1000	1000	1000	3000
test	1000	1000	1000	3000


実験結果

評価項目	正答率[%]
positive	89.8
negative	73.7
neutral	74.8
test accuracy	79.43

- positiveは高い精度で分類できた。
- 一方, negativeとneutralは比較的低い精度となった。

実験結果

正解＼予測	negative	neutral	positive
negative	73.7%	21.1%	5.2%
neutral	17.5%	74.8%	7.7%
positive	4.4%	5.8%	89.8%



正negative→誤neutral **21.1%**
正neutral→誤negative **17.5%**で混同が多い。
正positive→正positive **89.8%**で高精度。

画像分類例

	positive	negative	neutral
正分類例	True: positive Pred: positive (98.9%) 	True: negative Pred: negative (80.5%) 	True: neutral Pred: neutral (90.1%) 
誤分類例	True: positive Pred: negative (49.4%)  正positive→誤negative	True: negative Pred: neutral (60.3%)  正negative→誤neutral	True: neutral Pred: negative (96.9%)  正neutral→誤negative

negative内訳

内訳	negative 判定	neutral 判定	positive 判定	正解率
angry	374/500	94/500	32/500	74.8%
sad	323/500	160/500	17/500	64.6%

sad由来画像はnegativeとして判定されにくく、neutralに誤分類されやすい傾向が見られた。

考察

■ 実験結果

- positiveは89.8%と高い精度で分類できた
- negativeとneutralの混同が多かった
- sadはneutralに誤分類されやすい傾向が見られた



- sadとneutralは表情特徴が近い
- negativeはangry, sadの統合であるため、クラス内のばらつきが大きい
- 低解像度画像では細かな表情差が判別しにくい

- より高解像度なデータセットを利用する
- sadとneutralの境界付近のデータを追加する
- angry / sad / neutral / positive の4クラス分類と比較する

まとめ

■ 実験を通して

- 画像認識技術の基礎の理解
- CNNや転移学習を用いた画像分類の流れの理解

■ 今後の予定

- 画像認識技術を用いた研究内容の検討
- 他の画像認識技術についても学習




評価指標の算出方法

- 正解率[%]

$$\text{正解率} = \frac{\text{出力結果に含まれる正解数}}{\text{出力結果の数}} \times 100$$


Shortcut Connection

- 勾配消失問題、劣化問題を解決する仕組み
 - 勾配消失問題：浅い層の重みがほとんど更新されない問題
 - 劣化問題：層を増やすと逆に訓練誤差が悪化する問題




Batch Normalization(バッチ正規化)

- 内部共変量問題の解決
- 各レイヤが独立して学習可能となり、学習が安定化、高速化
- 畳み込みや全結合の後などに実行




Residual Block(残差ブロック)

- Shortcut Connectionを用いて残差関数を学習
- 入力を後段に足し合わせることで，劣化問題を抑える
- ResNet18ではBasic Block /Plain構造を採用




ResNet18, 34



Plain構造

ResNet50, 101, 152



Bottleneck構造